Del prototipo LLM a un sistema RAG evaluable

Desacuerdos entre artículos científicos mediante citation context, recuperación híbrida y generación estructurada

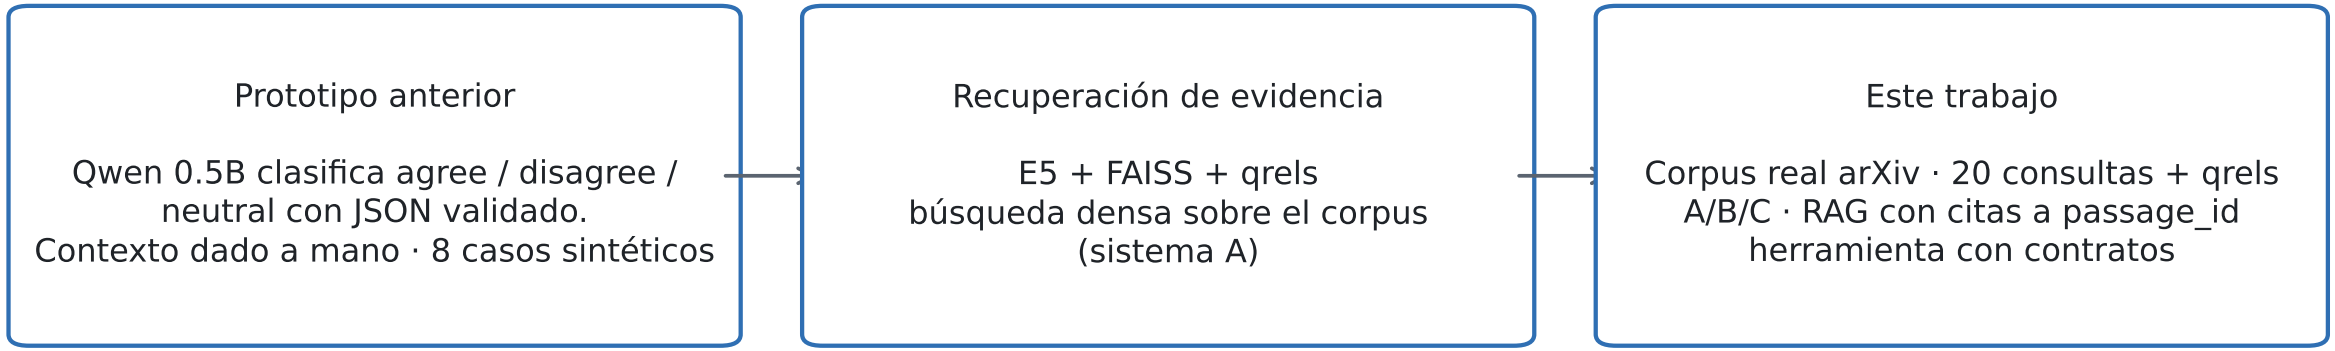
César Augusto Sánchez Malaspina

CC0F4 Tópicos de Ciencia de la Computación I · 2026-2 · Examen Parcial

Qwen2.5-0.5B-Instruct · multilingual-e5-small · BM25 · RRF · mMiniLM Cross-Encoder

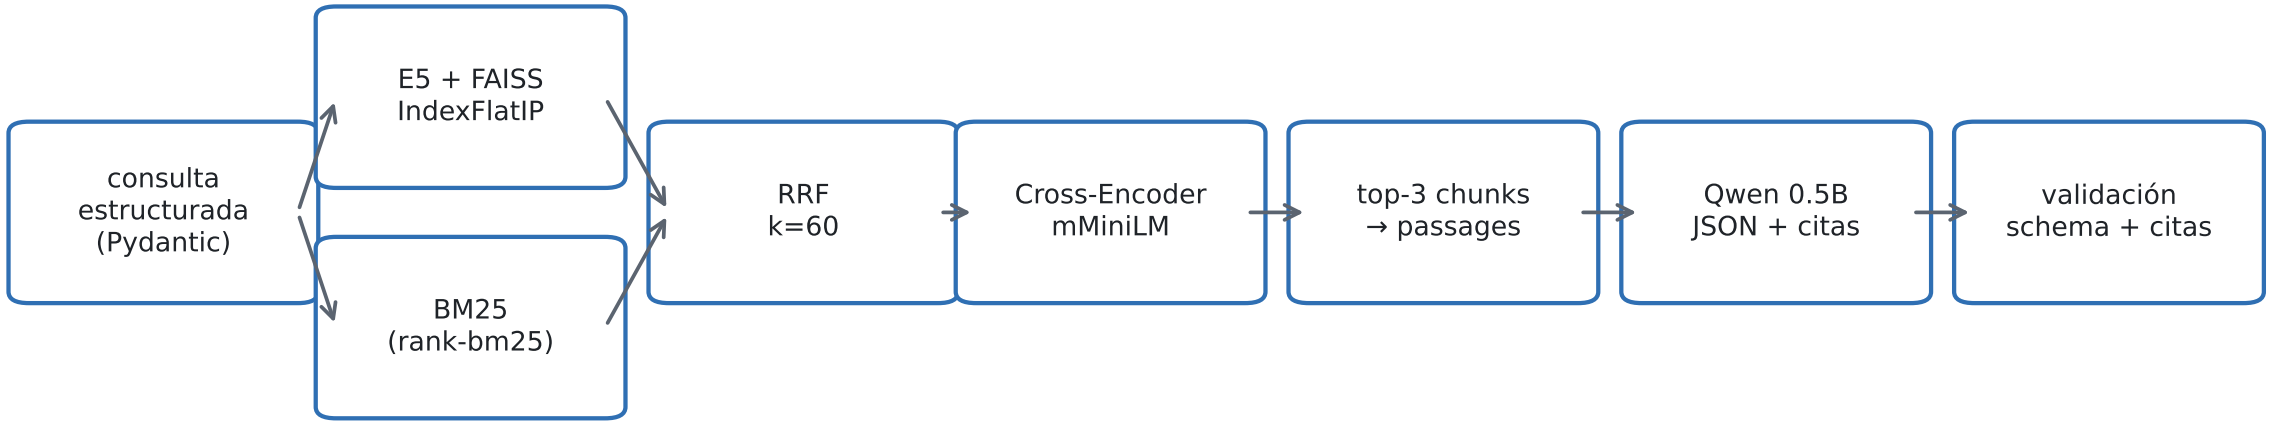
1. Problema y continuidad

¿Coinciden o discrepan dos líneas de trabajo sobre una misma afirmación, y con qué evidencia?



- Pregunta experimental: ¿qué aporta cada etapa de recuperación y cuánto cambia la respuesta del mismo LLM con evidencia?
- Se reutiliza del prototipo: el modelo, las etiquetas agree / disagree / neutral y la validación JSON en 3 niveles.
- Se corrige del prototipo: el decoding 'greedy' tenía repetition_penalty=1.1 oculto y dos conclusiones no coincidían con su tabla.
- Fuera de alcance (según el enunciado): agentes, ReAct, memoria, interfaz gráfica.

2. Arquitectura y datos



A = E5 + FAISS B = A + BM25 + RRF C = B + Cross-Encoder

Herramienta independiente: citation.check_temporal_validity
contrato → dominio → ejecución / ToolError

- 36 artículos reales de arXiv (2017-2024), 12 debates de ML/NLP. Licencia de metadatos: CC0.
- 135 passages (unidad de relevancia) → 110 chunks (100 palabras, overlap de 1 passage).
- 20 consultas: 10 claras, 3 ambiguas, 5 difíciles, 2 con distractor. Más 2 sin respuesta para medir la abstención.
- 56 juicios graduados (2 = directa, 1 = parcial), anotados antes de correr los sistemas.
- IDs estables: 2203.15556-P02 = arXiv ID + número de passage. Versión de arXiv y SHA-256 registrados.

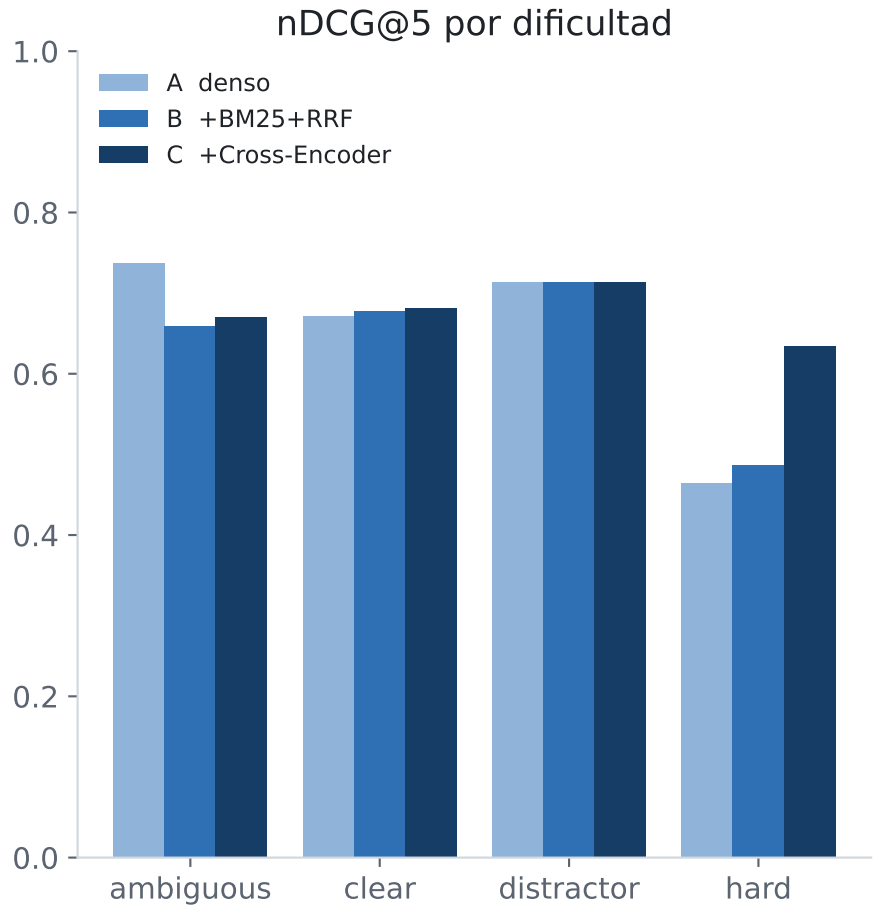
3. Conceptos aplicados

Concepto	Dónde se aplica	Evidencia
Transformer causal y GQA	Inspección de Qwen	24 capas · 14 cabezas Q / 2 K/V · atención a tokens futuros = 0.0
Decoding y KV cache	Generación RAG	greedy · P(primer token) = 0.77 · KV 24 KB/token (7× menos que MHA)
Salida estructurada (JSON Schema)	Consultas y respuestas	Pydantic · JSON válido: RAG 83% vs closed-book 25% · validación de citas
Chunking y embeddings	Sistema A	110 chunks de 100 palabras, overlap 1 · E5 dim 384 · FAISS IndexFlatIP
Recuperación híbrida y reranking	Sistemas B y C	BM25 (k1=1.5, b=0.75) · RRF k=60 · Cross-Encoder sobre 10 candidatos
RAG y grounding	Experimento 2	citas a passage_id · abstención · auditoría manual por afirmación
Contratos de herramientas	Experimento 3	validación · retry con backoff · timeout y deadline · 12/12 casos
Evaluación	Experimentos 1 y 2	Recall@k · MRR · nDCG@5 graduado · bootstrap pareado (IC95)

4. Experimento 1 · Recuperación A / B / C

- Se compararon tres sistemas sobre las mismas 20 consultas, 110 chunks y qrels: A (E5 + FAISS), B (A + BM25 fusionados con RRF) y C (B + reranking con Cross-Encoder). Se midieron Recall@k, MRR y nDCG@5 a nivel de passage y la latencia por consulta.

sistema	recall@1	recall@3	recall@5	mrr	ndcg@5	ms/consulta
A denso	0.221	0.642	0.762	0.75	0.634	10.4
B +BM25+RRF	0.262	0.567	0.754	0.785	0.631	10.6
C +Cross-Encoder	0.221	0.617	0.825	0.758	0.671	263.3

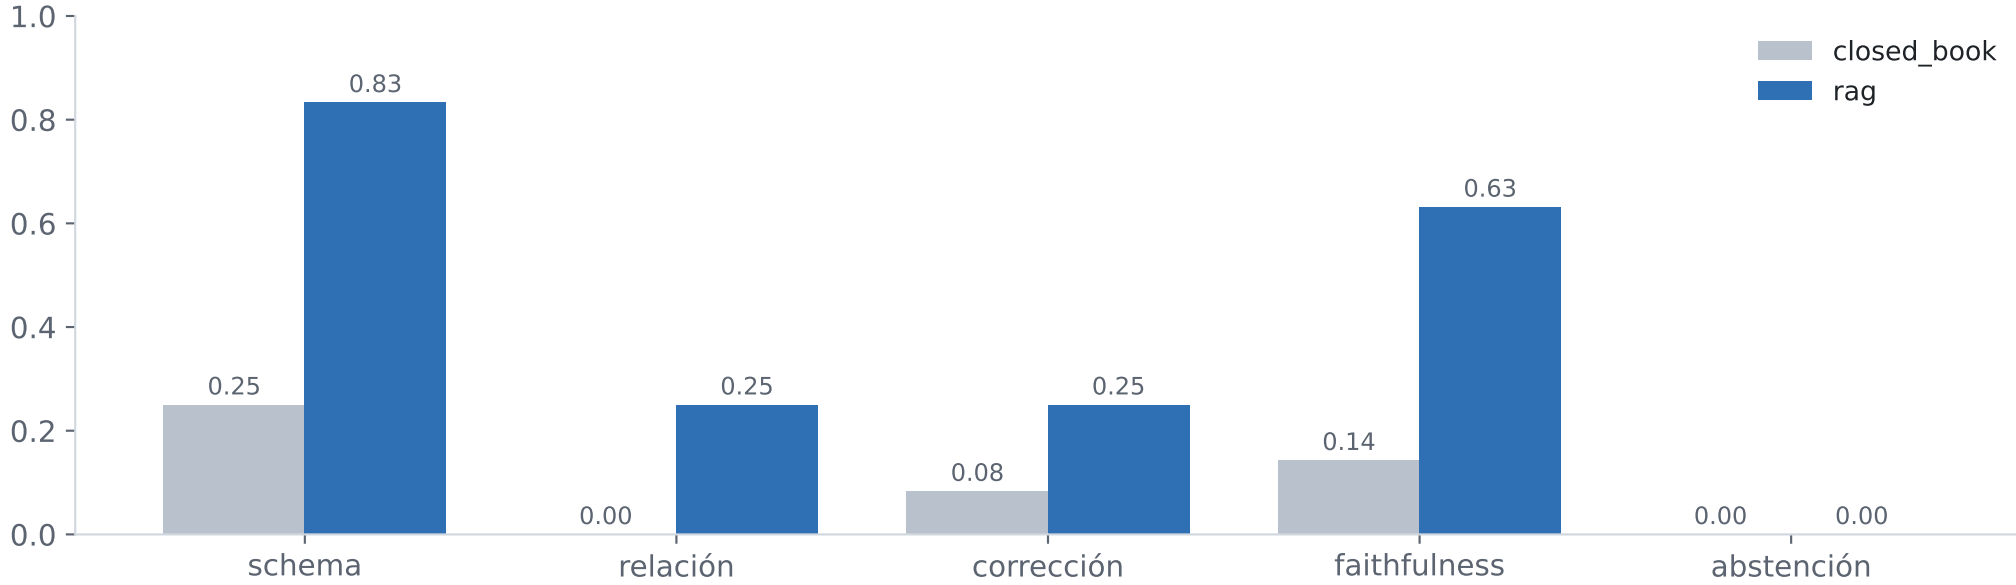


5. Experimento 2 · Closed-book vs RAG

- Se comparó el mismo LLM (Qwen2.5-0.5B, greedy) sin evidencia (closed-book) y con los top-3 chunks del sistema C (RAG), sobre las mismas 12 preguntas: 10 con respuesta en el corpus y 2 sin respuesta. Se evaluó el formato del JSON y, con auditoría manual, la corrección, las citas y la fidelidad de cada afirmación.

modo	schema	relación	corrección*	citas*	faithfulness*	abstención	ms
closed_book	0.25	0.00	0.08	—	0.14 (1/7)	0.00	1334
rag	0.83	0.25	0.25	0.21	0.63 (12/19)	0.00	4884

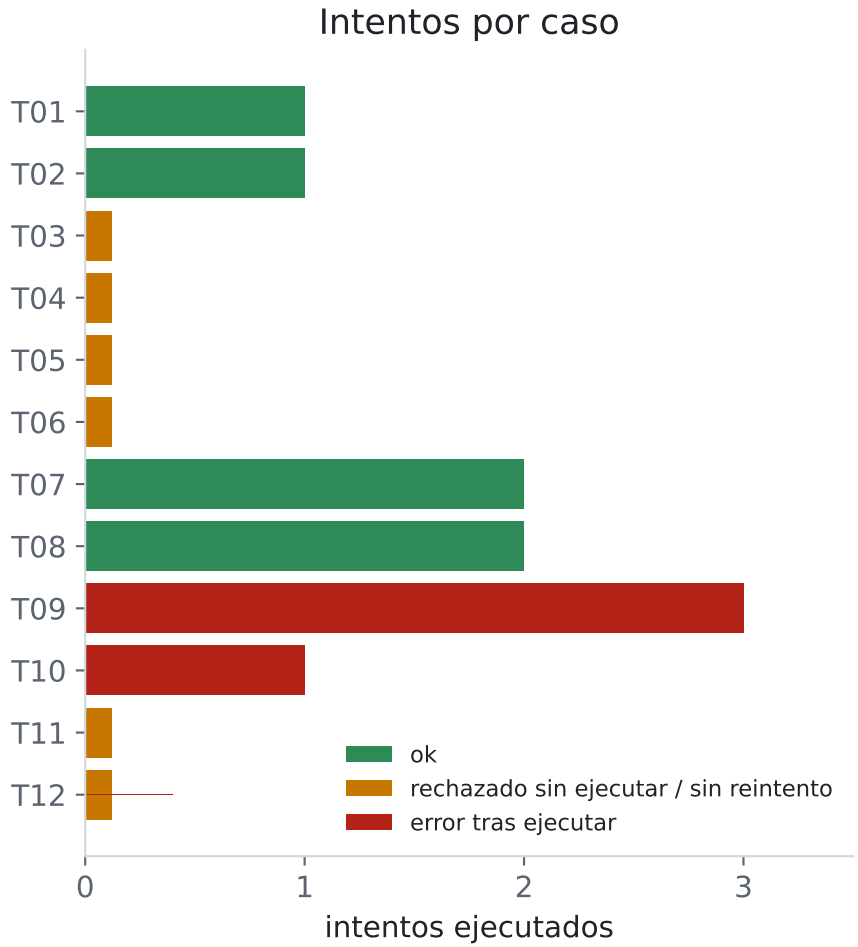
* auditoría manual por afirmación



6. Experimento 3 · Herramienta con contratos

- Se implementó citation.check_temporal_validity(citing_id, cited_id), que verifica con el catálogo de arXiv si una cita es temporalmente posible. Flujo: allowlist → contrato de entrada → dominio → ejecución con timeout, reintentos y deadline → contrato de salida. Se probaron 12 casos con fallos inyectados.

case_id	fault	observado = esperado	error_code	attempts	ms
T01	none	ok ✓	—	1	0.56
T02	none	ok ✓	—	1	0.02
T03	none	validation ✓	invalid_arguments	0	0.08
T04	none	validation ✓	invalid_arguments	0	0.01
T05	none	domain ✓	unknown_paper	0	0.01
T06	none	domain ✓	self_citation	0	0.01
T07	transient_once	ok ✓	—	2	21.17
T08	slow_once	ok ✓	—	2	122.41
T09	slow_always	timeout ✓	attempt_timeout	3	365.73
T10	bad_output	output_contract ✓	invalid_tool_output	1	0.14
T11	none	protocol ✓	unknown_tool	0	0.02
T12	none	protocol ✓	malformed_tool_call	0	0.05



7. Resultados

- Recuperación: C obtiene el mayor nDCG@5 (0.671) y Recall@5 (0.825); B el mayor MRR (0.785); A y B quedan casi iguales en nDCG@5. La mayor diferencia está en las consultas difíciles (0.49 → 0.63), a ~25× la latencia de B.
- Con 20 consultas, los intervalos de confianza (bootstrap) de nDCG@5 entre sistemas incluyen el 0.
- Generación: con evidencia, el JSON válido pasa de 25% a 83% y la fidelidad de 14% a 63%; la relación correcta llega a 25% y ninguna de las 2 preguntas sin respuesta se abstiene.
- La evidencia correcta estuvo en el contexto en las 10 preguntas con respuesta.
- Herramienta: 12/12 casos con el resultado esperado; solo los fallos transitorios y los timeouts se reintentan, el resto se rechaza antes de ejecutar.

Limitaciones

- 20 consultas y un solo anotador: los resultados son descriptivos, no prueban generalización estadística.
- Solo abstracts en inglés, un único LLM de 0,5B y latencias medidas en CPU con 1 hilo.